

4장. 표본 분포

4.3 순서통계량의 분포

예 4.3.1

표준지수분포 $\text{Exp}(1)$ 에서의 랜덤표본 X_1, X_2, X_3 을 크기 순서로 늘어놓은 순서통계량을

$X_{(1)} < X_{(2)} < X_{(3)}$ 이라고 할 때 $Y = (X_{(1)}, X_{(2)}, X_{(3)})^t$ 의 결합확률밀도함수를 구하여라.

[풀이] 순서통계량을 나타내는 함수를 $u(X_1, X_2, X_3) = (X_{(1)}, X_{(2)}, X_{(3)})^t$ 라고 하면, 함수 u 는

$$X = \{(x_1, x_2, x_3)^t : x_i > 0 (i = 1, 2, 3), x_1 \neq x_2, x_2 \neq x_3, x_3 \neq x_1\}$$

에서

$$Y = \{(y_1, y_2, y_3)^t : 0 < y_1 < y_2 < y_3\}$$

로의 3!대일 함수로서 다대일 변환에 관한 정리 4.1.2의 조건을 만족하는 것을 알 수 있다.

구체적으로, $\{1, 2, 3\}$ 에서의 치환(置換 permutation)을 π 로 나타내고

$$X_\pi = \{(x_1, x_2, x_3)^t : 0 < x_{\pi 1} < x_{\pi 2} < x_{\pi 3}\}$$

라고 하면 함수 u 에서 정의역을 X_π 로 제한한 함수

$$u^\pi(x_1, x_2, x_3) = (x_{\pi 1}, x_{\pi 2}, x_{\pi 3})^t, x \in X_\pi$$

는 각각 X_π 에서 Y 로의 일대일 함수로서 미분가능하며

$$J_{u^\pi}(x) = \det\left(\frac{\partial x_{\pi j}}{\partial x_i}\right) = \pm 1 \quad \forall x \in X_\pi$$

임을 알 수 있다. 예를 들어 $(\pi 1, \pi 2, \pi 3) = (3, 2, 1)$ 인 경우에

$$J_{u^\pi}(x) = \det\begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix} = -1$$

따라서 정리 4.1.2의 공식으로부터 $Y = (X_{(1)}, X_{(2)}, X_{(3)})^t$ 의 결합확률밀도함수는

다음과 같이 주어진다.

$$\begin{aligned} pdf_Y(y) &= \sum_{\pi} pdf_X((u^\pi)^{-1}(y)) |J_{(u^\pi)^{-1}}(y)|, y \in Y \\ &= \sum_{\pi} pdf_X(y_{\pi^{-1}1}, y_{\pi^{-1}2}, y_{\pi^{-1}3}) |\pm 1|, y \in Y \end{aligned}$$

한편 $X = (X_1, X_2, X_3)^t$ 의 결합확률밀도함수는

$$pdf_X(x_1, x_2, x_3) = e^{-(x_1 + x_2 + x_3)} I_{(x_1 > 0, x_2 > 0, x_3 > 0)}$$

이고 치환 π 의 개수는 $3! = 6$ 개이므로

$$\begin{aligned} pdf_Y(y_1, y_2, y_3) &= \sum_{\pi} e^{-(y_{\pi^{-1}1} + y_{\pi^{-1}2} + y_{\pi^{-1}3})}, y \in Y \\ &= 6e^{-(y_1 + y_2 + y_3)} I_{(0 < y_1 < y_2 < y_3)} \end{aligned}$$

정리 4.3.1: 순서통계량의 결합확률밀도함수

모집단 분포가 연속형이고 그 확률밀도함수가 $f(x)$ 일 때, 랜덤포본 X_1, X_2, \dots, X_n 을 크기 순서로 늘어놓은 순서통계량을 $X_{(1)} < X_{(2)} < \dots < X_{(n)}$ 이라고 하면 $Y = (X_{(1)}, X_{(2)}, \dots, X_{(n)})^t$ 의 결합확률밀도함수는 다음과 같이 주어진다.

$$pdf_Y(y_1, \dots, y_n) = n! f(y_1) \cdots f(y_n) I_{(y_1 < \dots < y_n)}$$

[증명] 순서통계량을 나타내는 함수를 $u(X_1, \dots, X_n) = (X_{(1)}, \dots, X_{(n)})^t$ 이라고 하면, 함수 u 는

$$X = \{(x_1, \dots, x_n)^t : f(x_i) > 0 (i = 1, \dots, n), x_1, \dots, x_n \text{은 서로 다른 실수}\}$$

에서

$$Y = \{(y_1, \dots, y_n)^t : f(y_i) > 0 (i = 1, \dots, n), y_1 < \dots < y_n\}$$

로의 $n!$ 대일 함수로서 다대일 변환에 관한 정리 4.1.2의 조건을 만족하는 것을 알 수 있다.

구체적으로, $\{1, \dots, n\}$ 에서의 치환(置換 permutation)을 π 로 나타내고

$$X_\pi = \{(x_1, \dots, x_n)^t : f(x_i) > 0 (i = 1, \dots, n), x_{\pi_1} < \dots < x_{\pi_n}\}$$

라고 하면 함수 u 에서 정의역을 X_π 로 제한한 함수

$$u^\pi(x_1, \dots, x_n) = (x_{\pi_1}, \dots, x_{\pi_n})^t, x \in X_\pi$$

는 각각 X_π 에서 Y 로의 일대일 함수로서 미분가능하며 일차편도함수의 행렬 $(\frac{\partial x_{\pi_j}}{\partial x_i})$ 은 단위행렬의 행과 열을 치환해놓은 행렬인 것을 알 수 있다. 따라서

$$J_{u^\pi}(x) = \det\left(\frac{\partial x_{\pi_j}}{\partial x_i}\right) = \pm 1 \quad \forall x \in X_\pi$$

이고 정리 4.1.2의 공식으로부터 $Y = (X_{(1)}, \dots, X_{(n)})^t$ 의 결합확률밀도함수는

$$\begin{aligned} pdf_Y(y) &= \sum_{\pi} pdf_X((u^\pi)^{-1}(y)) |J_{(u^\pi)^{-1}}(y)|, y \in Y \\ &= \sum_{\pi} pdf_X(y_{\pi^{-1}1}, \dots, y_{\pi^{-1}n}) |\pm 1|, y \in Y \end{aligned}$$

한편 $X = (X_1, \dots, X_n)^t$ 의 결합확률밀도함수는

$$pdf_X(x_1, \dots, x_n) = f(x_1) \cdots f(x_n)$$

이고 치환 π 의 개수는 $n!$ 개이므로

$$\begin{aligned} pdf_Y(y_1, \dots, y_n) &= \sum_{\pi} f(y_{\pi^{-1}1}) \cdots f(y_{\pi^{-1}n}), y \in Y \\ &= n! f(y_1) \cdots f(y_n) I_{(y_1 < \dots < y_n)} \end{aligned}$$

순서통계량의 주변확률밀도함수의 직관적 유도 과정:

$X_{(r)}$ 이 x 근방에 있을 사건 $(x < X_{(r)} \leq x + |\Delta x|)$ 은 X_1, \dots, X_n 들 중에서 $(r-1)$ 개는 x 이하이고 1개는 x 와 $x + |\Delta x|$ 사이에 그리고 나머지 $(n-r)$ 개는 $x + |\Delta x|$ 를 초과하는 사건으로 나타내어진다. 그런데 X_1, \dots, X_n 은 서로 독립이고 동일한 분포를 따르므로 이러한 사건의 확률은 다음과 같이 나타낼 수 있다.

$$P(x < X_{(r)} \leq x + |\Delta x|) \approx c_r [P(X_1 \leq x)]^{r-1} P(x < X_1 \leq x + |\Delta x|) [P(X_1 > x + |\Delta x|)]^{n-r}$$

여기에서 c_r 은 서로 다른 n 개 중에서 $(r-1)$ 개, 1개, $(n-r)$ 개를 뽑아서 각각 세 개의 구간 $(-\infty, x], (x, x + |\Delta x|], (x + |\Delta x|, +\infty)$ 에 넣는 방법의 수를 나타내는 상수이다. 즉

$$c_r = \frac{n!}{(r-1)!1!(n-r)!}$$

따라서 모집단의 확률밀도함수와 누적분포함수를 각각 f 와 F 라고 하면

$$pdf_{X_{(r)}}(x) |\Delta x| \approx c_r [F(x)]^{r-1} f(x) |\Delta x| [1 - F(x)]^{n-r}$$

정리 4.3.2: 순서통계량의 주변확률밀도함수

모집단 분포가 연속형이고 그 확률밀도함수가 $f(x)$ 이고 누적분포함수가 $F(x)$ 일 때, 랜덤포본 X_1, \dots, X_n 을 크기 순서로 늘어놓은 순서통계량을 $X_{(1)} < \dots < X_{(n)}$ 이라고 하면 이들의 일차원 또는 이차원 주변확률밀도함수가 다음과 같이 주어진다.

(a) ($X_{(r)}$ 의 확률밀도함수) ($1 \leq r \leq n$)

$$pdf_{X_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!} [F(x)]^{r-1} f(x) [1-F(x)]^{n-r}$$

(b) ($(X_{(r)}, X_{(s)})^t$ 의 확률밀도함수) ($1 \leq r < s \leq n$)

$$pdf_{X_{(r)}, X_{(s)}}(x, y) = \frac{n!}{(r-1)!(s-1-r)!(n-s)!} [F(x)]^{r-1} f(x) [F(y)-F(x)]^{s-1-r} f(y) [1-F(y)]^{n-s}$$

[증명] 정리 4.3.1에 주어진 $(X_{(1)}, \dots, X_{(n)})^t$ 의 결합확률밀도함수를 $f_{1, \dots, n}(y_1, \dots, y_n)$ 으로 나타내고, $X_{(r)}$ 과 $(X_{(r)}, X_{(s)})^t$ 의 주변확률밀도함수를 각각 $f_r(x), f_{r,s}(x, y)$ 로 나타내면

$$f_r(x) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f_{1, \dots, n}(y_1, \dots, x, \dots, y_n) dy_1 \dots dy_{r-1} dy_{r+1} \dots dy_n$$

$$f_{r,s}(x, y) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f_{1, \dots, n}(y_1, \dots, x, \dots, y, \dots, y_n) dy_1 \dots dy_{r-1} dy_{r+1} \dots dy_{s-1} dy_{s+1} \dots dy_n$$

이러한 적분에서 피적분함수의 적분 변수들에 대한 대칭성(symmetry)을 이용....

예 4.3.2 균등분포에서의 순서통계량:

균등분포 $U(0,1)$ 에서의 랜덤포본 n 개에 기초한 순서통계량을 $X_{(1)} < \dots < X_{(n)}$ 이라고 할 때 다음을 밝혀라.

(a) $X_{(r)} \sim \text{Beta}(r, n-r+1)$, 즉 $X_{(r)}$ 의 확률밀도함수는

$$f_r(x) = \frac{n!}{(r-1)!(n-r)!} x^{r-1} (1-x)^{n-r} I_{(0,1)}(x)$$

(b) $Z = (X_{(1)}, X_{(2)} - X_{(1)}, \dots, X_{(n)} - X_{(n-1)})^t \sim \text{Dirichlet}(1, \dots, 1)$, 즉 Z 의 확률밀도함수는

$$pdf_Z(z_1, \dots, z_n) = \frac{\Gamma(n+1)}{\Gamma(1) \dots \Gamma(1)} I_{(z_1 > 0, \dots, z_n > 0, z_1 + \dots + z_n < 1)}$$

[풀이] (a)는 정리 4.3.2로부터 명백하다. 또한 정리 4.3.1로부터 $Y = (X_{(1)}, \dots, X_{(n)})^t$ 의 결합확률밀도함수는

$$pdf_Y(y_1, \dots, y_n) = n! I_{(0 < y_1 < \dots < y_n < 1)}$$

한편 $Z = (X_{(1)}, X_{(2)} - X_{(1)}, \dots, X_{(n)} - X_{(n-1)})^t$ 와 $Y = (X_{(1)}, \dots, X_{(n)})^t$ 에 대하여

$$Z = (Z_1, \dots, Z_n)^t = u((Y_1, \dots, Y_n)^t) = u(Y)$$

라고 하면 다음과 같이 함수 u 와 그 정의역 Y , 치역 Z , 역함수 u^{-1} 를 생각할 수 있다.

$$u : \begin{cases} z_1 = y_1 \\ z_2 = y_2 - y_1 \\ \vdots \\ z_n = y_n - y_{n-1} \end{cases} \quad u^{-1} : \begin{cases} y_1 = z_1 \\ y_2 = z_1 + z_2 \\ \vdots \\ y_n = z_1 + z_2 + \dots + z_n \end{cases}$$

$$Y = \{(y_1, \dots, y_n)^t : 0 < y_1 < \dots < y_n < 1\}$$

$$Z = \{(z_1, \dots, z_n)^t : z_i > 0 (i = 1, \dots, n), z_1 + \dots + z_n < 1\}$$

함수 u 는 Y 에서 Z 로의 일대일 함수로서 정리 4.1.1의 조건을 만족시키고 그 역함수 u^{-1} 의 야코비안 값은 1이므로 $Z = (X_{(1)}, X_{(2)} - X_{(1)}, \dots, X_{(n)} - X_{(n-1)})^t$ 의 결합확률밀도함수는

$$pdf_Z(z_1, \dots, z_n) = n! I_{(z_1 > 0, \dots, z_n > 0, z_1 + \dots + z_n < 1)}$$

예 4.3.3 지수분포에서의 순서통계량:

지수분포 $\text{Exp}(1)$ 에서의 랜덤포본 n 개에 기초한 순서통계량 $X_{(1)} < \dots < X_{(n)}$ 에 대하여

$$Z_1 = nX_{(1)}, Z_2 = (n-1)(X_{(2)} - X_{(1)}), \dots, Z_n = X_{(n)} - X_{(n-1)}$$

이라고 할 때 Z_1, Z_2, \dots, Z_n 은 서로 독립이고 각각 지수분포 $\text{Exp}(1)$ 를 따르는 것을 밝혀라.

[풀이] $Y = (Y_1, Y_2, \dots, Y_n) = (X_{(1)}, X_{(2)} - X_{(1)}, \dots, X_{(n)} - X_{(n-1)})^t$ 이라고 하면 정리 4.3.1로부터

$$pdf_Y(y_1, \dots, y_n) = n! e^{-(y_1 + \dots + y_n)} I_{(0 < y_1 < \dots < y_n)}$$

한편 $Z = (nX_{(1)}, (n-1)(X_{(2)} - X_{(1)}), \dots, X_{(n)} - X_{(n-1)})^t$ 와 $Y = (X_{(1)}, X_{(2)} - X_{(1)}, \dots, X_{(n)} - X_{(n-1)})^t$ 에 대하여

$$Z = (Z_1, \dots, Z_n)^t = u((Y_1, \dots, Y_n)^t) = u(Y)$$

라고 하면 다음과 같이 함수 u 와 그 정의역 Y , 치역 Z , 역함수 u^{-1} 를 생각할 수 있다.

$$u: \begin{cases} z_1 = ny_1 \\ z_2 = (n-1)(y_2 - y_1) \\ \vdots \\ z_n = y_n - y_{n-1} \end{cases} \quad u^{-1}: \begin{cases} y_1 = \frac{1}{n}z_1 \\ y_2 = \frac{1}{n}z_1 + \frac{1}{n-1}z_2 \\ \vdots \\ y_n = \frac{1}{n}z_1 + \frac{1}{n-1}z_2 + \dots + \frac{1}{1}z_n \end{cases}$$

$$Y = \{(y_1, \dots, y_n)^t : 0 < y_1 < \dots < y_n\}$$

$$Z = \{(z_1, \dots, z_n)^t : z_1 > 0, \dots, z_n > 0\}$$

함수 u 는 Y 에서 Z 로의 일대일 함수로서 정리 4.1.1의 조건을 만족시키고 그 역함수 u^{-1} 의 야코비안 값은 $1/n!$, $y_1 + \dots + y_n = z_1 + \dots + z_n$ 이므로 Z 의 결합확률밀도함수는

$$pdf_Z(z_1, \dots, z_n) = n! e^{-(z_1 + \dots + z_n)} I_{(z_1 > 0, \dots, z_n > 0)} \frac{1}{n!} = \prod_{i=1}^n \{e^{-z_i} I_{(0, \infty)}(z_i)\}$$

지수분포에서의 순서통계량 분포의 대의적 정의:

지수분포 $\text{Exp}(1)$ 에서의 랜덤포본 n 개에 기초한 순서통계량을 $X_{(1)} < \dots < X_{(n)}$ 이라고 하면

$$(X_{(r)})_{1 \leq r \leq n} \stackrel{d}{=} \left(\frac{1}{n}Z_1 + \dots + \frac{1}{n-r+1}Z_r \right)_{1 \leq r \leq n}, \quad Z_r \stackrel{iid}{\sim} \text{Exp}(1) \quad (r = 1, \dots, n)$$

정리 4.3.3: 확률적분변환(確率積分變換 probability integral transformation)¹⁾

확률변수 X 가 연속형이고 그 누적분포함수 F 가 순증가함수 즉

$$x_1 < x_2 \text{ 이면 } F(x_1) < F(x_2)$$

일 때 그 역함수를 F^{-1} 라고 하면 다음이 성립한다.

(a) $F(X) \sim U(0,1)$, 즉 $F(X)$ 는 균등분포 $U(0,1)$ 을 따른다.

(b) 균등분포 $U(0,1)$ 을 따르는 확률변수 U 에 대하여

$$F^{-1}(U) \stackrel{d}{=} X$$

즉 $F^{-1}(U)$ 의 누적분포함수는 F 로서 $F^{-1}(U)$ 와 X 는 같은 분포를 갖는다.

[증명] 주어진 조건하에서 역함수 F^{-1} 도 순증가하고 다음이 성립하는 것을 알 수 있다.

$$F(x) \leq u \Leftrightarrow x \leq F^{-1}(u), \quad F^{-1}(u) \leq x \Leftrightarrow u \leq F(x), \quad F(F^{-1}(u)) = u$$

$$(a) \quad P(F(X) \leq u) = P(X \leq F^{-1}(u)) = F(F^{-1}(u)) = u \quad \forall u: 0 \leq u \leq 1$$

$$\therefore F(X) \sim U(0,1)$$

$$(b) \quad P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x) \quad \forall x: -\infty < x < +\infty$$

$$\therefore F^{-1}(U) \stackrel{d}{=} X$$

예 4.3.4 균등분포와 지수분포에서의 순서통계량:

균등분포 $U(0,1)$ 에서의 랜덤포본 n 개에 기초한 순서통계량을 $U_{(1)} < \dots < U_{(n)}$ 이라고 하고 지수분포 $\text{Exp}(1)$ 에서의 랜덤포본 n 개에 기초한 순서통계량을 $Y_{(1)} < \dots < Y_{(n)}$ 이라고 하면

$$(U_{(r)})_{1 \leq r \leq n} \stackrel{d}{=} (1 - e^{-Y_{(r)}})_{1 \leq r \leq n}$$

[풀이] 지수분포 $\text{Exp}(1)$ 에서의 랜덤포본을 Y_1, Y_2, \dots, Y_n 이라고 할 때, 지수분포의 누적분포함수가

$$G(y) = \begin{cases} 1 - e^{-y}, & y \geq 0 \\ 0, & y < 0 \end{cases}$$

이므로 정리 4.3.3으로부터

$$G(Y_i) \stackrel{iid}{\sim} U(0,1)$$

또한 누적분포함수는 증가함수이므로

$$(G(Y_{(r)}))_{1 \leq r \leq n} \stackrel{d}{=} (U_{(r)})_{1 \leq r \leq n}$$

1) 누적분포함수가 순증가는 아닌 증가함수인 경우에는 F 의 역변환을

$$F^{-1}(u) = \inf\{x : F(x) \geq u\} \quad (0 \leq u \leq 1)$$

로 정의하고, 이 역변환에 대하여 정리의 (b)가 일반적인 확률변수에 대하여도 성립한다.

정리 4.3.4: 순서통계량 분포의 대의적 정의

모집단 분포가 연속형이고 그 누적분포함수가 $F(x)$ 일 때 랜덤포본 n 개에 기초한 순서통계량을 $X_{(1)} < \dots < X_{(n)}$ 이라고 하면 $h(y) = F^{-1}(1 - e^{-y})I_{(0,+\infty)}(y)$ 로 정의된 함수 h 에 대하여

$$(X_{(r)})_{1 \leq r \leq n} \stackrel{d}{=} \left(h\left(\frac{1}{n}Z_1 + \dots + \frac{1}{n-r+1}Z_r\right) \right)_{1 \leq r \leq n}, \quad Z_r \stackrel{iid}{\sim} \text{Exp}(1) \ (r = 1, \dots, n)$$

[증명] 균등분포 $U(0,1)$ 에서의 랜덤포본 n 개에 기초한 순서통계량을 $U_{(1)} < \dots < U_{(n)}$ 이라고 하면 정리 4.3.3으로부터

$$(X_{(r)})_{1 \leq r \leq n} \stackrel{d}{=} (F^{-1}(U_{(r)}))_{1 \leq r \leq n}$$

한편 지수분포 $\text{Exp}(1)$ 에서의 랜덤포본 n 개에 기초한 순서통계량을 $Y_{(1)} < \dots < Y_{(n)}$ 이라고 하면 예 4.3.4로부터

$$(U_{(r)})_{1 \leq r \leq n} \stackrel{d}{=} (1 - e^{-Y_{(r)}})_{1 \leq r \leq n}$$

$$\therefore (X_{(r)})_{1 \leq r \leq n} \stackrel{d}{=} (h(Y_{(r)}))_{1 \leq r \leq n}$$

또한 예 4.3.3으로부터

$$(Y_{(r)})_{1 \leq r \leq n} \stackrel{d}{=} \left(\frac{1}{n}Z_1 + \dots + \frac{1}{n-r+1}Z_r \right)_{1 \leq r \leq n}, \quad Z_r \stackrel{iid}{\sim} \text{Exp}(1) \ (r = 1, \dots, n)$$

따라서 정리에 주어진 대의적 정의를 얻게 된다.

4.4 다변량 정규분포(多變量 正規分布 multivariate normal distribution)

정리 4.4.1

표준정규분포 $N(0,1)$ 을 따르고 서로 독립인 확률변수 Z_1, Z_2, \dots, Z_n 과 상수의 행렬과 벡터

$$A = (a_{ij})_{\substack{1 \leq i \leq n \\ 1 \leq j \leq n}}, \quad \mu = (\mu_1, \mu_2, \dots, \mu_n)^t$$

에 대하여

$$\begin{cases} X_1 = a_{11}Z_1 + \dots + a_{1n}Z_n + \mu_1 \\ \vdots \\ X_n = a_{n1}Z_1 + \dots + a_{nn}Z_n + \mu_n \end{cases} \quad \Leftrightarrow \quad X = AZ + \mu, \quad X = (X_1, \dots, X_n)^t, Z = (Z_1, \dots, Z_n)^t$$

이라고 할 때, 다음이 성립한다.

(a) 행렬 A 가 정칙행렬(정칙행렬 nonsingular matrix)이면 $X = AZ + \mu$ 의 확률밀도함수는

$$pdf_X(x) = (\det(2\pi\Sigma))^{-1/2} \exp\left\{-\frac{1}{2}(x-\mu)^t \Sigma^{-1}(x-\mu)\right\}, \quad x \in R^n \quad (\Sigma = AA^t)$$

(b) $X = AZ + \mu$ 의 적률생성함수는

$$mgf_X(t) = \exp\left(\mu^t t + \frac{1}{2} t^t \Sigma t\right), \quad t \in R^n$$

[증명] 정리 3.6.1로부터 $Z = (Z_1, Z_2, \dots, Z_n)^t$ 의 확률밀도함수와 적률생성함수는 각각

$$pdf_Z(z) = (2\pi)^{-\frac{n}{2}} e^{-\frac{1}{2}(z_1^2 + \dots + z_n^2)} = (2\pi)^{-\frac{n}{2}} e^{-\frac{1}{2}z^t z}, \quad z \in R^n$$

$$mgf_Z(s) = e^{\frac{1}{2}(s_1^2 + \dots + s_n^2)} = e^{\frac{1}{2}s^t s}, \quad s \in R^n$$

(a) $X = u(Z) = AZ + \mu$ 에 대하여 정리 4.1.1 적용

$$pdf_X(x) = pdf_Z(u^{-1}(x)) |J_{u^{-1}}(x)| = (2\pi)^{-n/2} \exp\left\{-\frac{1}{2}(A^{-1}(x-\mu))^t A^{-1}(x-\mu)\right\} (\det(A))^{-1}$$

$$pdf_X(x) = (\det(2\pi\Sigma))^{-1/2} \exp\left\{-\frac{1}{2}(x-\mu)^t \Sigma^{-1}(x-\mu)\right\} \quad \Sigma = AA^t$$

(b) $mgf_X(t) = E[\exp\{t^t(AZ + \mu)\}] = mgf_Z(A^t t) \exp(t^t \mu)$

$$\therefore mgf_X(t) = \exp\left\{\mu^t t + \frac{1}{2}(A^t t)^t (A^t t)\right\} = \exp\left(\mu^t t + \frac{1}{2} t^t \Sigma t\right)$$

정리 4.4.2

(a) 정리 4.4.1에서 $X = AZ + \mu$ 의 분포를 $X \sim N(\mu, \Sigma)$ 라고 나타내면

$$E(X) = \mu, \quad \text{Var}(X) = \Sigma$$

(b) 분산행렬 Σ 에 대하여 $AA^t = \Sigma$, $A = A^t$ 인 행렬 A 를 $\Sigma^{1/2}$ 이라고 하면²⁾

$$X \sim N_n(\mu, \Sigma) \Leftrightarrow X \overset{d}{=} \Sigma^{1/2}Z + \mu, \quad Z \sim N_n(0, I)$$

[증명] (a) $N(\mu, \Sigma)$ 의 누율생성함수 $C(t) = \log mgf_X(t) = \mu^t t + \frac{1}{2} t^t \Sigma t$ 의 미분

(b) $mgf_{\Sigma^{1/2}Z + \mu}(t) = \exp\left(\mu^t t + \frac{1}{2} t^t \Sigma t\right), \quad t \in R^n$

2) 정리 2.5.4로부터 분산행렬 Σ 는 음이 아닌 정부호의 행렬이고, 부록 II에서 이러한 행렬에 대하여 $\Sigma^{1/2} \Sigma^{1/2} = \Sigma$ 인 대칭행렬 $\Sigma^{1/2}$ 이 존재하는 것을 밝히고 있다.

다변량 정규분포의 정의:

$$Z \sim N_n(0, I) \Leftrightarrow Z = (Z_1, \dots, Z_n)^t, \quad Z_i \stackrel{iid}{\sim} N(0, 1) \quad (i = 1, \dots, n)$$

$$X \sim N_n(\mu, \Sigma) \Leftrightarrow (1)^3) \quad X \stackrel{d}{=} AZ + \mu, \quad Z \sim N(0, I), \quad AA^t = \Sigma$$

$$\Leftrightarrow (2) \quad X \stackrel{d}{=} \Sigma^{1/2}Z + \mu, \quad Z \sim N_n(0, I), \quad \Sigma^{1/2}\Sigma^{1/2} = \Sigma, \quad \Sigma^{1/2} = (\Sigma^{1/2})^t$$

$$\Leftrightarrow (3) \quad mgf_X(t) = \exp\left(\mu^t t + \frac{1}{2}t^t \Sigma t\right), \quad t \in R^n$$

$$\Leftrightarrow (4) \quad (\text{분산행렬 } \Sigma \text{ 가 정칙행렬인 경우})$$

$$pdf_X(x) = (\det(2\pi\Sigma))^{-1/2} \exp\left\{-\frac{1}{2}(x-\mu)^t \Sigma^{-1}(x-\mu)\right\}, \quad x \in R^n$$

예 4.4.1 이변량 정규분포 $N\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}\right)$ 또는 $N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2, \rho)$:

분산행렬 Σ 에 대하여 $\det(\Sigma) = \sigma_1^2\sigma_2^2(1-\rho^2)$ 이므로, $\sigma_1 > 0, \sigma_2 > 0, -1 < \rho < 1$ 이면

$$\Sigma^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)} \begin{pmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{pmatrix}$$

$$pdf(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2}Q}$$

$$Q = \frac{1}{1-\rho^2} \left\{ \left(\frac{x_1-\mu_1}{\sigma_1} \right)^2 - 2\rho \left(\frac{x_1-\mu_1}{\sigma_1} \right) \left(\frac{x_2-\mu_2}{\sigma_2} \right) + \left(\frac{x_2-\mu_2}{\sigma_2} \right)^2 \right\}$$

한편 $\sigma_1 > 0, \sigma_2 > 0, \rho = \pm 1$ 인 경우에는 분산행렬의 역행렬이 존재하지 않고 정리 2.2.3으로부터 다음과 같이 두 변수 사이에 선형 관계가 성립하는 것을 알 수 있다.

$$\rho = 1 \Leftrightarrow P\left(\frac{X_2 - \mu_2}{\sigma_2} = \frac{X_1 - \mu_1}{\sigma_1}\right) = 1, \quad \rho = -1 \Leftrightarrow P\left(\frac{X_2 - \mu_2}{\sigma_2} = -\frac{X_1 - \mu_1}{\sigma_1}\right) = 1$$

정리 4.4.3: 다변량 정규분포의 성질

(a) $X \sim N(\mu, \Sigma)$ 이면 상수의 행렬과 벡터 A 와 b 에 대하여

$$AX + b \sim N(A\mu + b, A\Sigma A^t)$$

(b) $\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}\right)$ 일 때, $\text{Cov}(X_1, X_2) = \Sigma_{12} = 0$ 이면 X_1 과 X_2 는 서로 독립이다.

(c) $X \sim N(\mu, \Sigma)$ 이고 A, B 가 상수의 행렬일 때, $\text{Cov}(AX, BX) = A\Sigma B^t = 0$ 이면 AX 와 BX 는 서로 독립이다.

[증명] (a) 다변량 정규분포의 정의 (2)와 (1) 적용

(b) 정의 (3)으로부터 주어지는 다음과 같은 X_1 과 X_2 의 결합적률생성함수이용

$$mgf_{X_1, X_2}(t_1, t_2) = \exp\left\{\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}^t \begin{pmatrix} t_1 \\ t_2 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} t_1 \\ t_2 \end{pmatrix}^t \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \begin{pmatrix} t_1 \\ t_2 \end{pmatrix}\right\}$$

(c) (a)와 (b) 이용

3) 정의 (1)에서 A 가 $n \times n$ 정방행렬이어야만 하는 것은 아니며 $AA^t = \Sigma$ 인 $n \times m$ 행렬이어도 무방하다.

정리 4.4.4: 다변량 정규분포의 주변분포와 조건부분포

(a) (주변분포) $\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}\right)$ 이면

$$X_1 \sim N(\mu_1, \Sigma_{11})$$

(b) (조건부분포) $\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}\right)$ 이고 분산행렬이 정칙행렬이면

$$X_{2|X_1=x_1} \sim N(\mu_2 + \Sigma_{21}\Sigma_{11}^{-1}(x_1 - \mu_1), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$$

[증명] (a) $X_1 = (I, 0)\begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$ 와 정리 4.4.3의 (a) 이용

(b) 이 경우의 분산행렬과 같이 부분행렬로 분할되어 있는 정칙행렬에 대하여

$$\det\left[\begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}\right] = \det(\Sigma_{11})\det(\Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$$

이고 $\Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}$ 라고 하면

$$\begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}^{-1} = \begin{pmatrix} \Sigma_{11}^{-1} + \Sigma_{11}^{-1}\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}\Sigma_{11}^{-1} - \Sigma_{11}^{-1}\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}\Sigma_{11}^{-1} & -\Sigma_{11}^{-1}\Sigma_{12}\Sigma_{22}^{-1} \\ -\Sigma_{22}^{-1}\Sigma_{21}\Sigma_{11}^{-1} & \Sigma_{22}^{-1} \end{pmatrix}$$

임이 알려져 있다.⁴⁾ 이 사실을 이용하여 **조건부분포의 확률밀도함수**

$$pdf_{X_2|X_1=x_1}(x_2|x_1) = pdf_{X_1, X_2}(x_1, x_2)/pdf_{X_1}(x_1)$$

를 계산하여 (b)를 밝힐 수 있다.

또는 (b)와

$$X_2 - \mu_2 - \Sigma_{21}\Sigma_{11}^{-1}(X_1 - \mu_1)|_{X_1=x_1} \sim N(0, \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$$

가 동등한 것을 이용하여 다음과 같이 (b)를 밝힐 수도 있다.

$$\begin{pmatrix} X_1 - \mu_1 \\ X_2 - \mu_2 - \Sigma_{21}\Sigma_{11}^{-1}(X_1 - \mu_1) \end{pmatrix} = \begin{pmatrix} I & 0 \\ -\Sigma_{21}\Sigma_{11}^{-1} & I \end{pmatrix} \begin{pmatrix} X_1 - \mu_1 \\ X_2 - \mu_2 \end{pmatrix}$$

$$\begin{pmatrix} I & 0 \\ -\Sigma_{21}\Sigma_{11}^{-1} & I \end{pmatrix} \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \begin{pmatrix} I & 0 \\ -\Sigma_{21}\Sigma_{11}^{-1} & I \end{pmatrix}^t = \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12} \end{pmatrix}$$

따라서 정리 4.4.3의 (a)로부터

$$\begin{pmatrix} X_1 - \mu_1 \\ X_2 - \mu_2 - \Sigma_{21}\Sigma_{11}^{-1}(X_1 - \mu_1) \end{pmatrix} \sim N\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & 0 \\ 0 & \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12} \end{pmatrix}\right)$$

그러므로 정리 4.4.3의 (b)로부터 $X_1 - \mu_1$ 과 $X_2 - \mu_2 - \Sigma_{21}\Sigma_{11}^{-1}(X_1 - \mu_1)$ 은 서로 독립이고

$$X_2 - \mu_2 - \Sigma_{21}\Sigma_{11}^{-1}(X_1 - \mu_1) \sim N(0, \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$$

이다. 따라서 (b)의 조건부분포가 성립한다.

예 4.4.3 이변량 정규분포 $N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2, \rho)$ 에서의 조건부분포:

$$X_{2|X_1=x_1} \sim N(\mu_2 + \rho\sigma_2(x_1 - \mu_1)/\sigma_1, \sigma_2^2(1 - \rho^2))$$

4) 부분행렬로 분할된 행렬에 관한 이러한 사실은 부록 II에 증명되어 있다.

부록 II: 행렬 대수 (p.513~514)

분할된 행렬의 덧셈과 곱셈:

A_{ij}, B_{ij} 가 행렬인 경우에

$$\begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} + \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix} = \begin{pmatrix} A_{11} + B_{11} & A_{12} + B_{12} \\ A_{21} + B_{21} & A_{22} + B_{22} \end{pmatrix} \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix} = \begin{pmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{12}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{pmatrix}$$

분할된 행렬의 행렬식:

$$(a) \det \begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix} = \det(A)\det(B)$$

$$(b) \det \begin{pmatrix} A & C \\ 0 & B \end{pmatrix} = \det(A)\det(B)$$

$$(c) A_{11}^{-1} \text{가 존재할 때, } \det \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} = \det(A_{11})\det(A_{22} - A_{21}A_{11}^{-1}A_{12})$$

[증명] (a) 다음 등식과 행렬식의 귀납적 정의로부터 명백하다.

$$\begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix} = \begin{pmatrix} A & 0 \\ 0 & I \end{pmatrix} \begin{pmatrix} I & 0 \\ 0 & B \end{pmatrix}$$

(b) $\det(A) = 0$ 인 경우에는 (b)의 성립이 명백하고, $\det(A) \neq 0$ 인 경우에는 등식

$$\begin{pmatrix} A & C \\ 0 & B \end{pmatrix} = \begin{pmatrix} A & 0 \\ 0 & B \end{pmatrix} \begin{pmatrix} I & A^{-1}C \\ 0 & I \end{pmatrix}, \det \begin{pmatrix} I & D \\ 0 & I \end{pmatrix} = 1$$

로부터 (b)가 성립하는 것을 알 수 있다.

(c) 다음 등식과 (a), (b)로부터 (c)가 성립하는 것은 명백하다.

$$\begin{pmatrix} I & 0 \\ -A_{21}A_{11}^{-1} & I \end{pmatrix} \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} \begin{pmatrix} I & -A_{11}^{-1}A_{12} \\ 0 & I \end{pmatrix} = \begin{pmatrix} A_{11} & 0 \\ 0 & A_{22} - A_{21}A_{11}^{-1}A_{12} \end{pmatrix}$$

분할된 행렬의 역행렬:

A_{11}^{-1} 가 존재하고 $A_{22} \cdot 1 = A_{22} - A_{21}A_{11}^{-1}A_{12}$ 의 역행렬도 존재할 때

$$\begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}^{-1} = \begin{pmatrix} A_{11}^{-1} + A_{11}^{-1}A_{12}A_{22}^{-1} \cdot 1 & -A_{11}^{-1}A_{12}A_{22}^{-1} \cdot 1 \\ -A_{22}^{-1} \cdot 1 A_{21}A_{11}^{-1} & A_{22}^{-1} \cdot 1 \end{pmatrix}$$

[증명] 행렬식의 증명에서와 같이 다음 등식으로부터 역행렬을 구할 수 있다.

$$\begin{aligned} & \begin{pmatrix} I & 0 \\ -A_{21}A_{11}^{-1} & I \end{pmatrix} \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} \begin{pmatrix} I & -A_{11}^{-1}A_{12} \\ 0 & I \end{pmatrix} = \begin{pmatrix} A_{11} & 0 \\ 0 & A_{22} - A_{21}A_{11}^{-1}A_{12} \end{pmatrix} \\ & \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} = \begin{pmatrix} I & 0 \\ -A_{21}A_{11}^{-1} & I \end{pmatrix}^{-1} \begin{pmatrix} A_{11} & 0 \\ 0 & A_{22} \cdot 1 \end{pmatrix} \begin{pmatrix} I & -A_{11}^{-1}A_{12} \\ 0 & I \end{pmatrix}^{-1} \\ & \therefore \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}^{-1} = \begin{pmatrix} I & -A_{11}^{-1}A_{12} \\ 0 & I \end{pmatrix} \begin{pmatrix} A_{11}^{-1} & 0 \\ 0 & A_{22}^{-1} \cdot 1 \end{pmatrix} \begin{pmatrix} I & 0 \\ -A_{21}A_{11}^{-1} & I \end{pmatrix} \end{aligned}$$

대칭행렬의 대각화 정리:

원소가 실수인 $m \times m$ 행렬 A 가 대칭행렬이면

$$Ax_i = \lambda_i x_i, x_i^t x_i = 1, x_i^t x_j = 0 (i \neq j) (i, j = 1, 2, \dots, m)$$

를 만족시키는 실수의 고유값 λ_i 와 실수 성분의 고유벡터 $x_i (i = 1, \dots, m)$ 이 존재한다. 즉

$$A = P \text{diag}(\lambda_i) P^t, PP^t = P^t P = I$$

인 직교행렬 $P = (x_1, x_2, \dots, x_m)$ 가 존재한다.

정리 4.4.5: 이차형식의 분포

(a) $X \sim N_k(\mu, \Sigma)$ 이고 분산행렬 Σ 가 정칙행렬이면

$$(X - \mu)^t \Sigma^{-1} (X - \mu) \sim \chi^2(k)$$

(b) $Z \sim N(0, I)$ 일 때, $A^2 = A$ 이면 $Z^t A Z \sim \chi^2(r)$ 이고 자유도는 $r = \text{trace}(A)$ 이다.⁵⁾

[증명] (a) $\Sigma^{1/2} \Sigma^{1/2} = \Sigma$ 인 대칭행렬 $\Sigma^{1/2}$ 의 역행렬을 $\Sigma^{-1/2}$ 이라고 하면

$$\Sigma^{-1/2} (X - \mu) \sim N_k(0, I)$$

따라서 $Z = (Z_1, \dots, Z_k)^t = \Sigma^{-1/2} (X - \mu)$ 라고 하면

$$(X - \mu)^t \Sigma^{-1} (X - \mu) = Z^t Z = Z_1^2 + \dots + Z_k^2, \quad Z_i \stackrel{iid}{\sim} N(0, 1) (i = 1, \dots, k)$$

$$\therefore (X - \mu)^t \Sigma^{-1} (X - \mu) \sim \chi^2(k)$$

(b) 행렬 A 는 원소가 실수인 대칭행렬이므로 다음과 같이 대각화가 가능하다.⁶⁾

$$A = P^t \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} P, \quad P^t P = P P^t = I$$

여기에서 $\lambda_1, \dots, \lambda_n$ 은 $\det(A - \lambda I) = 0$ 을 만족하는 λ 값들로서, $A^2 = A$ 인 경우에는 $\lambda_i^2 = \lambda_i$ 이어야 하므로 λ_i 는 0 또는 1 임을 알 수 있다. 이들 중 r 개만 1이고 나머지는 0이라고 하면 $\lambda_1 = \dots = \lambda_r = 1, \lambda_{r+1} = \dots = \lambda_n = 0$ 이라고 가정할 수 있다.

$$\therefore Z^t A Z = (PZ)^t \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} (PZ)$$

그러므로 $X = (X_1, \dots, X_n)^t = PZ$ 라고 하면

$$Z^t A Z = X^t \begin{bmatrix} I_r & 0 \\ 0 & 0 \end{bmatrix} X = X_1^2 + \dots + X_r^2, \quad X \sim N_n(0, P P^t) = N_n(0, I)$$

$$\therefore Z^t A Z = X_1^2 + \dots + X_r^2, \quad X_i \stackrel{iid}{\sim} N(0, 1) (i = 1, \dots, r)$$

그러므로 카이제곱분포의 대의적 정의로부터

$$Z^t A Z \sim \chi^2(r)$$

5) 일반적으로 $x^t A x = x^t \left(\frac{A + A^t}{2} \right) x$ 이므로 이차형식 $Z^t A Z$ 에서 행렬 A 는 언제나 대칭행렬인 것으로

가정되어 있으며, (b)에서의 조건 $A^2 = A$ 는 $Z^t A Z \sim \chi^2(r)$ 이기 위한 충분조건일 뿐만 아니라 필요조건인 것도 알려져 있다. 여기에서 $\text{trace}(A)$ 는 행렬 A 의 모든 대각원소의 합이다.

6) 원소가 실수인 대칭행렬의 대각화에 대한 정리는 부록 II에 주어져 있으며, $\det(A - \lambda I) = 0$ 을 만족하는 λ 값은 행렬 A 의 고유값(固有값 characteristic value)이라고 한다.

예 4.4.6 표본분산의 표본분포:

정규분포 $N(\mu, \sigma^2)$ 에서의 랜덤표본을 X_1, X_2, \dots, X_n 이라고 할 때, 표본평균 \bar{X} 와 표본분산 $S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 / (n-1)$ 은 서로 독립이고 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ 인 것을 정리 4.2.2로부터 이미 알고 있다. 이제 다변량 정규분포에 관한 정리들을 이용하여 이를 밝히는 방법을 알아보자. 이를 위하여 $X = (X_1, \dots, X_n)^t$ 라고 하면

$$X \sim N_n(\mu 1, \sigma^2 I), \quad 1 = (1, \dots, 1)^t$$

$$\bar{X} = n^{-1} 1^t X, \quad (n-1)S^2 = \sum_{i=1}^n (X_i - \bar{X})^2 = X^t (I - n^{-1} 11^t) X$$

한편 $I - n^{-1} 11^t$ 은 대칭행렬이고 $1^t (I - n^{-1} 11^t) = 0$ 이므로

$$\text{Cov}(1^t X, (I - n^{-1} 11^t) X) = 1^t (\sigma^2 I) (I - n^{-1} 11^t)^t = 0$$

따라서 정리 4.4.3의 (c)로부터 $\bar{X} = n^{-1} 1^t X$ 와 $(I - n^{-1} 11^t) X$ 은 서로 독립이다. 그런데

$$(I - n^{-1} 11^t)^2 = I - n^{-1} 11^t$$

이므로

$$X^t (I - n^{-1} 11^t) X = [(I - n^{-1} 11^t) X]^t [(I - n^{-1} 11^t) X]$$

그러므로 \bar{X} 와 $(n-1)S^2 = X^t (I - n^{-1} 11^t) X$ 은 서로 독립이다.

또한

$$X^t (I - n^{-1} 11^t) X / \sigma^2 = (X - \mu 1)^t (I - n^{-1} 11^t) (X - \mu 1) / \sigma^2$$

이고

$$(X - \mu 1) / \sigma \sim N_n(0, I), \quad (I - n^{-1} 11^t)^2 = I - n^{-1} 11^t, \quad \text{trace}(I - n^{-1} 11^t) = n-1$$

이므로 정리 4.4.5의 (b)로부터

$$(n-1)S^2 / \sigma^2 = X^t (I - n^{-1} 11^t) X / \sigma^2 \sim \chi^2(n-1)$$

선형회귀모형: 정규 오차항을 갖는 경우

$$\begin{cases} Y_i = x_{i0}\beta_0 + x_{i1}\beta_1 + \cdots + x_{ip}\beta_p + e_i \\ e_i \stackrel{iid}{\sim} N(0, \sigma^2), i = 1, \cdots, n \end{cases}$$

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, X = \begin{pmatrix} x_{10} & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & & \vdots \\ x_{n0} & x_{n1} & \cdots & x_{np} \end{pmatrix}, \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, e = \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix}$$

라고 하면 위의 모형을 다음과 같이 간략하게 나타낼 수 있다.

$$\begin{cases} Y = X\beta + e \\ e \sim N_n(0, \sigma^2 I), \text{rank}(X) = p + 1 \end{cases}$$

표본회귀계수(표본회귀계수 sample regression coefficient):

$$\hat{\beta} = (X^t X)^{-1} X^t Y$$

평균오차제곱합(平均誤差제곱합 mean squared error sum of squares):

$$\hat{\sigma}^2 = (Y - X\hat{\beta})^t (Y - X\hat{\beta}) / (n - p - 1) = \sum_{i=1}^n (Y_i - \hat{\beta}_0 x_{i0} - \hat{\beta}_1 x_{i1} - \cdots - \hat{\beta}_p x_{ip})^2 / (n - p - 1)$$

예 4.4.7 단순선형회귀모형에서 표본회귀계수:

선형회귀모형에서 $p = 1$ 이고 $x_0 = 1$ 경우, 즉

$$\begin{cases} Y_i = \beta_0 + x_{i1}\beta_1 + e_i \\ e_i \stackrel{iid}{\sim} N(0, \sigma^2), i = 1, \cdots, n \end{cases}$$

로 나타내어지는 모형을 단순(單純 simple)선형회귀모형이라고 한다. 이 경우에는

$$X = \begin{pmatrix} 1 & x_{11} \\ \vdots & \vdots \\ 1 & x_{n1} \end{pmatrix}, X^t X = \begin{pmatrix} n & \sum_{i=1}^n x_{i1} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}^2 \end{pmatrix}, X^t Y = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_{i1} Y_i \end{pmatrix}$$

$$(X^t X)^{-1} = \frac{1}{n \sum_{i=1}^n x_{i1}^2 - (\sum_{i=1}^n x_{i1})^2} \begin{pmatrix} \sum_{i=1}^n x_{i1}^2 & -\sum_{i=1}^n x_{i1} \\ -\sum_{i=1}^n x_{i1} & n \end{pmatrix}$$

이므로 표본회귀계수 $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)^t$ 는 다음과 같이 주어진다.

$$\begin{aligned} \hat{\beta}_1 &= \frac{S_{xY}}{S_{xx}}, S_{xY} = \sum_{i=1}^n (x_{i1} - \bar{x}_1) Y_i, S_{xx} = \sum_{i=1}^n (x_{i1} - \bar{x}_1)^2, \bar{x}_1 = \sum_{i=1}^n x_{i1} / n \\ \hat{\beta}_0 &= \bar{Y} - \bar{x}_1 \hat{\beta}_1, \quad \hat{\beta}_0 + x_{i1} \hat{\beta}_1 = \bar{Y} + (x_{i1} - \bar{x}_1) \hat{\beta}_1 \end{aligned}$$

단순선형회귀모형에서 평균오차제곱합은

$$\hat{\sigma}^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1})^2 / (n - 2) = \sum_{i=1}^n (Y_i - \bar{Y} - \hat{\beta}_1 (x_{i1} - \bar{x}_1))^2 / (n - 2)$$

정리 4.4.6; 선형회귀모형에서 표본분포에 관한 기본 정리

선형회귀모형

$$\begin{cases} Y = X\beta + e \\ e \sim N_n(0, \sigma^2 I) \end{cases}$$

에서 주어진 상수의 행렬 X 는 $n \times (p+1)$ 행렬로서 계수가 $(p+1)$ 인 것으로 가정할 때 다음이 성립한다.

(a) $\hat{\beta} \sim N_{p+1}(\beta, \sigma^2(X^t X)^{-1})$

(b) 표본회귀계수 $\hat{\beta}$ 와 평균오차제곱합 $\hat{\sigma}^2$ 은 서로 독립이다.

(c) $(n-p-1)\hat{\sigma}^2/\sigma^2 \sim \chi^2(n-p-1)$

[증명] (a) $Y \sim N(X\beta, \sigma^2 I)$ 와 정리 4.4.3의 (a)이용

(b) $\Pi = X(X^t X)^{-1}X^t$ 라고 하면 Π 는 대칭행렬로서

$$\Pi^2 = X(X^t X)^{-1}X^t X(X^t X)^{-1}X^t = \Pi, \quad \Pi X = X(X^t X)^{-1}X^t X = X$$

$$Y - X\hat{\beta} = Y - \Pi Y = (I - \Pi)Y$$

$$\therefore \text{Cov}((X^t X)^{-1}X^t Y, (I - \Pi)Y) = (X^t X)^{-1}X^t(\sigma^2 I)(I - \Pi)^t = 0$$

정리 4.4.3의 (c)로부터 $\hat{\beta} = (X^t X)^{-1}X^t Y$ 와 $Y - X\hat{\beta} = (I - \Pi)Y$ 는 서로 독립

따라서 $\hat{\beta}$ 와 $\hat{\sigma}^2 = (Y - X\hat{\beta})^t(Y - X\hat{\beta})/(n-p-1)$ 이 서로 독립

(c) (b)에서의 행렬 Π 에 대하여

$$(I - \Pi)^2 = I - \Pi, \quad (I - \Pi)X = 0$$

이므로

$$(Y - X\hat{\beta})^t(Y - X\hat{\beta}) = Y^t(I - \Pi)^t(I - \Pi)Y = Y^t(I - \Pi)Y = (Y - X\beta)^t(I - \Pi)(Y - X\beta)$$

$$\therefore (n-p-1)\hat{\sigma}^2/\sigma^2 = (Y - X\hat{\beta})^t(Y - X\hat{\beta})/\sigma^2 = (Y - X\beta)^t(I - \Pi)(Y - X\beta)/\sigma^2$$

여기에서

$$(Y - X\beta)/\sigma \sim N_n(0, I), \quad (I - \Pi)^2 = (I - \Pi), \quad \text{trace}(I - \Pi) = n - p - 1$$

이므로 정리 4.4.5의 (b)로부터

$$(n-p-1)\hat{\sigma}^2/\sigma^2 = (Y - X\hat{\beta})^t(I - \Pi)(Y - X\hat{\beta})/\sigma^2 \sim \chi^2(n-p-1)$$

예 4.4.9 단순선형회귀모형에서의 표본분포:

예 4.4.7, 예 4.4.8과 정리 4.4.6으로부터 단순선형회귀모형에서는

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} \sim N\left(\begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \frac{\sigma^2}{S_{xx}} \begin{pmatrix} \sum_{i=1}^n x_{i1}^2/n & -\bar{x}_1 \\ -\bar{x}_1 & 1 \end{pmatrix}\right)$$

$$(n-2)\hat{\sigma}^2/\sigma^2 = \sum_{i=1}^n (Y_i - \bar{Y} - \hat{\beta}_1(x_{i1} - \bar{x}_1))^2/\sigma^2 \sim \chi^2(n-2)$$

이고 $\hat{\beta}$ 과 $\hat{\sigma}^2$ 이 독립이다. 따라서 t 분포의 대의적 정의로부터

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\hat{\sigma}^2/S_{xx}}} = \frac{(\hat{\beta}_1 - \beta_1)/\sqrt{\sigma^2/S_{xx}}}{\sqrt{(n-2)(\hat{\sigma}^2/\sigma^2)/(n-2)}} \sim t(n-2)$$

이 경우에 평균오차제곱합은 다음의 공식을 이용하여 계산할 수 있다.

$$\hat{\sigma}^2 = \sum_{i=1}^n (Y_i - \bar{Y} - \hat{\beta}_1(x_{i1} - \bar{x}_1))^2/(n-2) = \{S_{YY} - (S_{XY})^2/S_{xx}\}/(n-2)$$

$$S_{YY} = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

7) 행렬의 덧셈과 곱셈의 정의로부터 대각합에 대한 다음 성질이 성립하는 것은 명백하다.

$$\text{trace}(A + B) = \text{trace}(A) + \text{trace}(B), \quad \text{trace}(AB) = \text{trace}(BA)$$

$$\therefore \text{trace}(I_{n \times n} - X(X^t X)^{-1}X^t) = n - \text{trace}((X^t X)^{-1}X^t X) = n - p - 1$$